

Detecção de Anomalias com PCA

Decomposição espectral da covariância aplicada ao Processo Tennessee Eastman



Eduardo Soares Zanutti 10413611

Fábio Luiz Souza Alves 15084023

Reynaldo Pereira Martins 13490412

Victor Zoratti Ferreira 08006115

Monitorar dezenas de sensores em tempo real é inviável a olho nu

- Uma planta química moderna gera séries temporais de dezenas a centenas de sensores, simultaneamente e sem pausa.
- Inspecionar cada variável manualmente não escala — é preciso um detector automático de comportamento anormal (controles comportamentais)
- O Tennessee Eastman Process (TEP), de Downs & Vogel (1993), é o simulador de referência da área numa planta química industrial, observando os seguintes processos e equipamentos: reator (reação), compressor (pressão), condensador (resfriar e condensar), separador (gas e líquido) e reciclo de uma planta real.
- Pode ser utilizado em controlar a planta, detecção de falhas e controle preditivo
- Nesse trabalho vamos focar na detecção de falhas (algoritmo estatístico PCA) para diagnosticar anomalias antes de ocorrer paradas.
- Desafio sobre o tema: as variáveis são fortemente correlacionadas e a falha nem sempre aparece em variáveis isoladas.
- O objetivo operacional é converter de forma irreversível 4 reagentes em 2 produtos.

52

variáveis de processo

20

modos de falha catalogados (IDV 1–20)

5,25 mi

observações de treino (Rieth et al., 2017)

Anatomia dos dados: 52 variáveis (colunas) em cinco unidades



Reciclo (compressor) + purga fecham o circuito — esquema simplificado a partir dos nomes das variáveis (config.yaml).

XMEAS 1–22 (Indicadores ou KPI's)

Medições contínuas em tempo real

Vazões, pressões, níveis e temperaturas do reator, separador, alimentação, líquidos, vapores, stripper e compressor.

São medições diretas e isoladas do restante da cadeia

XMEAS 23–41 (Indicadores ou KPI's)

Analísadores de composição química

Divididos em 3 blocos de amostragem: Frações molares na alimentação do reator, no gás de purga e no produto.

Simulam a operação dos analisadores do processo em tempo real, ficar atento a atrasos e dados ausentes.

XMV 1–11 (Indicadores ou KPI's)

Variáveis manipuladas


Válvulas e fluxos de controle físicos na operação, ao contrário das variáveis de medida (XMEAS), eles são atuadores e devem ser usadas na correção de desvios, estabilização da planta e taxa de produção,

. O XMV(12), agitador, não é simulado neste dataset.

A ideia central: comprimir o “normal” e medir o que sobra

- As 52 variáveis são fortemente correlacionadas: o processo normal vive num subespaço de dimensão bem menor.
- Eles são analisados em conjuntos, pois caso ocorra uma falha na planta, o controlador automático vai abrir ou fechar de forma arbitrária as válvulas envolvida, tentando compensar o erro, deixando um “rastro claro” nos dados históricos.
- O PCA aprende esse “rastro claro” (subespaço) a partir dos dados de operação normal.
- O SPE (erro quadrático de predição, observa variações fora do modelo) — resume as 52 variáveis e dispara o alarme.
- O alarme dispara devido a quebra nas correlações físicas e químicas normais e o PCA perde a capacidade de prever o comportamento das variáveis. O SPE ultrapassa o limite de controle, ou seja, quebra correlação que faz o dado “escapar” do plano do PCA.

Variável a variável, a falha IDV(3) - identificar de distúrbio, é indistinguível do normal →



Séries de 6 variáveis em 3 cenários (linha vermelha = falha na amostra 20). Sob IDV(1) várias séries mudam; sob IDV(3) permanecem quase idênticas ao normal.

PCA para redução de dimensionalidade e reconstrução dos dados

1. Selecionar como conjunto de treino uma matriz de dados X_{nxd} , composta por n amostras/observações e d atributos, para uma condição normal de operação:

$$X_{nxd} = \begin{bmatrix} -x_{1xd}^{(1)} - \\ -x_{1xd}^{(2)} - \\ \vdots \\ -x_{1xd}^{(n)} - \end{bmatrix} = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \dots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(n)} & x_2^{(n)} & \dots & x_d^{(n)} \end{bmatrix}$$


1. Fazer a normalização da matriz de dados pela média e desvio padrão de cada atributo do conjunto de treino;
2. Fazer a modelagem do PCA e aplicar a transformação:
 - $pca.fit(X_{nxd})$
 - $T_{nxd} = pca.transform(X_{nxd})$
3. Aplicar a redução de dimensionalidade. Selecionar o número de componentes principais c menor do que d que represente bem a variabilidade original dos dados T_{nxc} ;
4. Fazer a reconstrução reprojando os dados transformados no espaço original:

$$\hat{X}_{nxd} = pca.inverse_transform(T_{nxc})$$

5. Calcular o erro de reconstrução para cada amostra do conjunto de treino através do quadrado da distância euclidiana da amostra $x_{1xd}^{(i)}$ original e a respectiva amostra reconstruída $\hat{x}_{1xd}^{(1)}$ chamado de Square Prediction Error (SPE):


$$SPE(x_{1xd}^{(i)}) = \|x_{1xd}^{(i)} - \hat{x}_{1xd}^{(1)}\|^2$$

PCA para redução de dimensionalidade e reconstrução dos dados



PCA para redução de dimensionalidade e reconstrução dos dados

6. Traçar a distribuição do SPE para todas as amostras do conjunto de treino (amostras sem anomalia) e escolher um determinado Limite de Aceitação. Por exemplo, selecionar o quantil de 0.99 ($q_{0.99}$) ou seja, o valor em que 99% do SPE das amostras de treino estejam abaixo:



PCA para redução de dimensionalidade e reconstrução dos dados

7. Selecionar como conjunto de teste uma matriz de dados $Y_{m \times d}$, composta por m novas amostras e os mesmos d atributos
8. Para a matriz do conjunto de teste, fazer a normalização utilizando a média e desvio padrão de cada atributo do conjunto de treino;
9. Aplicar a transformação dos dados para as mesmas componentes principais obtidas do conjunto de treino:
 - $P_{m \times d} = \text{pca.transfom}(Y_{m \times d})$
10. Aplicar a redução de dimensionalidade para as mesmas c componentes principais selecionadas no treino, e fazer a reconstrução reprojando os dados transformados para o espaço original
 - $\hat{Y}_{m \times d} = \text{pca.inverse_transfom}(P_{m \times c})$
11. Calcular o erro de reconstrução para cada amostra do conjunto de teste pelo SPE;

$$SPE \left(y_{1 \times d}^{(i)} \right) = \left\| y_{1 \times d}^{(i)} - \hat{y}_{1 \times d}^{(1)} \right\|^2$$

12. Se o SPE da amostra do conjunto de teste estiver abaixo do limite de aceitação definido anteriormente, a amostra é classificada como sendo **NORMAL (0)**, caso contrário, a amostra é classificada como sendo **ANOMALIA (1)**;

$$CLASSIFICAÇÃO \left(y_{1 \times d}^{(i)} \right) = \begin{cases} 0, & SPE \left(y_{1 \times d}^{(i)} \right) < q_{0.99} \\ 1, & SPE \left(y_{1 \times d}^{(i)} \right) \geq q_{0.99} \end{cases}$$

Treino, validação, teste e o limiar do SPE

Treino

1 simulação normal — 500 amostras

Estima V e Λ (PCA).

Validação

3 simulações normais — 1.500 amostras

Calibra o limiar $\bar{\sigma}^2$.

Teste

Simulações com falha IDV(1) e IDV(3)

Avalia a detecção.


```
1 # SPLIT TREINO / VALIDAÇÃO / TESTE
2 # Treino:   condição normal, simulação 1
3 # Validação: condição normal, simulações 2-4 → usado para calibrar o threshold
4 # Teste:   condições de falha, simulação 1 → avaliação de detecção
5
6 df_train    = df[(df['faultNumber'] == 0) & (df['simulationRun'] == 1)].iloc[:, 3:]
7 df_validation = df[(df['faultNumber'] == 0) & (df['simulationRun'].between(2, 4))].iloc[:, 3:]
```

Por que calibrar na validação?

Se o threshold fosse extraído dos próprios dados de treino, o modelo aprenderia o nível de ruído da amostra específica usada no treino, resultando em um limiar artificialmente otimista. Dados de validação independentes garantem uma estimativa conservadora e representativa da operação normal real.

Distribuição do SPE em validação; o limiar (99,99%) fica na cauda direita, em 25,45.


Componetes selecionadas



- Definiu um valor fixo de variância explicada e inteirou-se até chegar na variância explicada de 90%
- 30 de 52 para $\alpha = 90\%$ de variância explicada.

Distribuição do SPE em validação; o limiar (99,99%) fica na cauda direita, em 25,45.

IDV(1) é detectada; IDV(3) escapa



IDV(1) — degrau na razão A/C (corrente 4)

O SPE dispara logo após a amostra 20 e permanece acima do limiar (escala log).

IDV(3) — degrau na temperatura de alimentação D (corrente 2)

O SPE quase nunca ultrapassa o limiar: a falha é praticamente invisível a esse índice.


Resultados: taxa de detecção (FDR) e falso alarme (FAR)

Falha	Descrição	FDR	FAR
IDV(1)	Degrau na razão de alimentação A/C (corrente 4)	> 95%	< 1%
IDV(3)	Degrau na temperatura de alimentação D (corrente 2)	< 5%	< 1%

- FDR = fração de amostras pós-falha corretamente sinalizadas; FAR = fração de amostras pré-falha erroneamente sinalizadas.
- IDV(1): detecção rápida, poucas amostras após a introdução da falha na amostra 20.
- IDV(3): baixa FDR — a limitação estrutural conhecida do SPE (a explicação geométrica vem a seguir).

Valores conforme o manuscrito do repositório (docs/orientacao_wmecai.md); a saída numérica exata da célula de FDR não está salva no notebook.

Sensibilidade: curva ROC por fração de variância




- Varrendo α de 0,1 a 0,9 sobre todas as 20 falhas, a AUC do SPE fica entre $\sim 0,90$ e 0,94.
- A AUC é máxima em $\alpha = 0,1$ (0,936) e vale 0,901 em $\alpha = 0,9$: modelos mais compactos são levemente mais sensíveis ao conjunto heterogêneo de falhas.
- Nenhum α resolve falhas como IDV(3): elas se manifestam dentro do subespaço e exigem outro índice.

AUC agregada nas 20 falhas, com o limiar calibrado em validação.


O argumento geométrico: PC1 × PC2

Espaço das Componentes Principais — PC1 × PC2
(IDV(1) sai da nuvem normal; IDV(3) permanece misturado a ela)


Operação Normal



IDV(1) — Falha Detectável



IDV(3) — Falha Difícil



IDV(1): Falha detectável

Pontos pós-falha deixam a região normal → alto SPE → detectado.

IDV(3): Falha difícil

Pós-falha permanece na elipse → SPE insensível → não detectado.

Síntese e a limitação estrutural do SPE

IDV(1)

- FDR > 95%, detecção rápida após a amostra 20.
- A falha desloca o processo para fora de $\mathcal{S}_\square$.

IDV(3)


- FDR < 5%, limitação conhecida na literatura.
- A falha se manifesta dentro de $\mathcal{S}_\square$.

Por que o SPE falha em IDV(3)?

O erro de reconstrução mede apenas o que está FORA do subespaço principal. Uma falha que produz deslocamentos DENTRO de $\mathcal{S}_\square$ é, por construção, invisível ao SPE — não há resíduo para detectar.

Extensão: Modelos não lineares

- PCA não é só redução de dimensionalidade, é monitoramento estatístico fundamentado em álgebra linear
- O método é semi-supervisionado: treina apenas com dados normais
- A limitação do SPE para falhas "internas" ao subespaço motiva extensões não lineares (autoencoders)
- Baixo custo computacional, alta interpretabilidade



Trabalhos futuros

Spina et al. (2024)

- Evidência de que uma projeção não linear captura parte do que o PCA deixa passar.
- Para a Falha 3, o PCA tem o menor AUC (0,9779) entre os métodos comparados, enquanto os autoencoders alcançam até 0,9809.

Architecture	Undercomplete	Sparse
Autoencoder	0.9829	0.9809
Deep Autoencoder	0.9832	0.9795
Variational Autoencoder	0.9796	0.9835
Denoising Autoencoder	0.9813	0.9835
Deep Denoising Autoencoder	0.9812	0.9815
PCA	0.9779	

MENSAGEM CENTRAL

PCA + decomposição espectral entregam detecção de anomalias interpretável — e mostram, geometricamente, os limites do SPE.

PRINCIPAIS REFERÊNCIAS

- Downs & Vogel (1993). A plant-wide industrial process control problem. Computers & Chemical Engineering, 17(3), 245–255.
- Rieth, Amsel, Tran & Cook (2017). Additional TEP Simulation Data for Anomaly Detection. Harvard Dataverse, doi:10.7910/DVN/6C3JR1.
- Qin (2003). Statistical process monitoring: basics and beyond. Journal of Chemometrics, 17(8–9), 480–502.
- Spina et al. (2024). Comparison of Autoencoder Architectures for Fault Detection in Industrial Processes, Digital Chemical Engineering. doi:10.1016/j.dche.2024.100162

GRUPO I • MAI 5002 • FUNDAMENTOS DE MATEMÁTICA APLICADA

Eduardo Soares Zanutti 10413611

Fábio Luiz Souza Alves 15084023

Reynaldo Pereira Martins 13490412

Victor Zoratti Ferreira 08006115

