

Detecção de Anomalias em Processos Industriais via Análise de Componentes Principais: uma Aplicação ao Processo Tennessee Eastman

Eduardo Soares Zanutti¹ Fábio Luiz Souza Alves² Reynaldo Pereira Martins³ Victor Zoratti Ferreira⁴
ICMC-USP

1 Introdução

Processos industriais modernos operam com dezenas a centenas de sensores, gerando séries temporais multivariadas de alta dimensionalidade. Identificar manualmente quando o processo sai do comportamento normal é inviável na escala de dados industriais, tornando os métodos automáticos de detecção de anomalias essenciais para a segurança operacional e a qualidade de produto.

O **Monitoramento Estatístico de Processos** (Statistical Process Control, SPC) baseado em PCA constitui uma abordagem clássica e amplamente adotada na indústria química e petroquímica [1]. A ideia central é aprender, a partir de dados históricos, uma representação comprimida do comportamento normal do processo. Novas observações que não se encaixam nessa representação são sinalizadas como anômalas.

O **Processo Tennessee Eastman** (TEP) [2] é o simulador industrial mais utilizado como benchmark na literatura de monitoramento de processos. Ele modela uma planta química real com reações, separação e reciclo, gerando 52 variáveis de processo (temperatura, pressão, vazão, composição) sob 20 condições de falha distintas. O dataset de Rieth et al. [3] estende o TEP original com 500 simulações por condição, totalizando 5.250.000 observações de treino.

¹10413611

²15084023

³13490412

⁴08006115

2 Fundamentação Matemática

2.1 Decomposição Espectral e PCA

Seja $X \in \mathbb{R}^{n \times p}$ a matriz de dados normalizados com zero médio e desvio unitário. A matriz de covariância amostral $C = \frac{1}{n-1} X^T X$ é simétrica e semi-definida positiva; pelo **Teorema Espectral**, admite decomposição única:

$$C = V \Lambda V^T \quad (1)$$

onde $V = [v_1, \dots, v_p] \in \mathbb{R}^{p \times p}$ é a matriz ortonormal de **autovetores** (componentes principais) e $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$ a matriz diagonal de **autovalores**, com $\lambda_1 \geq \dots \geq \lambda_p \geq 0$.

A transformação $C\mathbf{x} = V(\Lambda(V^T \mathbf{x}))$ se decompõe em três operações: (1) **projeção** de $\mathbf{x}$ na base dos autovetores; (2) **escala** de cada coordenada pelo autovalor correspondente; (3) **reconstrução** no espaço original. Os autovalores correspondem às variâncias das coordenadas na nova base, e os autovetores definem as direções de máxima variância dos dados.

2.2 Subespaço de Operação Normal

Retendo os k maiores autovetores $V_k = [v_1, \dots, v_k]$ tal que

$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^p \lambda_i} \geq \alpha, \quad (2)$$

define-se o **subespaço de operação normal** $\mathcal{S}_k = \text{span}(V_k)$. O parâmetro $\alpha \in (0, 1]$ controla a capacidade do modelo: valores menores produzem subespaços mais compactos e detectores mais sensíveis a desvios gerais; valores maiores retêm mais variabilidade normal.

2.3 Squared Prediction Error (SPE)

Para uma nova observação $\mathbf{x} \in \mathbb{R}^p$, o **SPE** mede o erro de reconstrução ao projetar no subespaço principal:

$$\text{SPE}(\mathbf{x}) = \|\mathbf{x} - \hat{\mathbf{x}}\|^2, \quad \hat{\mathbf{x}} = V_k V_k^T \mathbf{x}. \quad (3)$$

Geometricamente, o SPE é a distância quadrada de $\mathbf{x}$ ao subespaço $\mathcal{S}_k$. A regra de decisão é:

$$\begin{cases} \text{SPE}(\mathbf{x}) \leq \delta^2 & \Rightarrow \text{operação normal,} \\ \text{SPE}(\mathbf{x}) > \delta^2 & \Rightarrow \text{anomalia detectada.} \end{cases} \quad (4)$$

O limiar δ^2 é o percentil 99,99% da distribuição do SPE em dados de validação independentes (operação normal não utilizada no treino), evitando o viés de estimativa nos próprios dados de ajuste.

3 Metodologia Experimental

3.1 Dados e Pré-processamento

Utilizamos o subconjunto de treino do dataset TEP de Rieth et al. [3], restringindo a análise às primeiras 10 simulações de cada condição operacional (105.000 observações). As 52 variáveis de processo são padronizadas com média e desvio calculados no conjunto de treino.

A divisão adotada é:

Conjunto	Condição	Simulações	Finalidade
Treino	Normal (<code>faultNumber</code> = 0)	1	Estimação de V e Λ via PCA
Validação	Normal (<code>faultNumber</code> = 0)	2–4	Calibração do limiar δ^2
Teste	Falha IDV(1) e IDV(3)	1	Avaliação da detecção

A introdução da falha ocorre na amostra 20 de cada simulação de teste. As amostras 1–20 são pré-falha (normais) e as amostras 21–500 são pós-falha.

3.2 Falhas Analisadas

Selecionamos duas falhas com comportamentos contrastantes:

- **IDV(1):** variação em degrau na razão de alimentação A/C (corrente 4). Espera-se alta taxa de detecção, pois a falha altera variáveis de processo que residem fora do subespaço normal.
- **IDV(3):** variação em degrau na temperatura de alimentação D (corrente 2). Falha de difícil detecção reportada na literatura: seu efeito projeta-se majoritariamente dentro de $\mathcal{S}_k$.

3.3 Métricas

- **FDR** (Fault Detection Rate): fração das amostras pós-falha corretamente sinalizadas.
- **FAR** (False Alarm Rate): fração das amostras pré-falha erroneamente sinalizadas.
- **AUC** (Área sob a curva ROC): capacidade discriminativa do score SPE bruto, avaliada varrendo todas as 20 falhas do dataset.

4 Resultados

4.1 Ajuste do Modelo

Com $\alpha = 0,90$, o PCA seleciona $k = 30$ componentes principais (de 52) para explicar 90% da variância de operação normal. O limiar SPE calibrado na validação é $\delta^2 = 25,45$.

4.2 Detecção por SPE

Para IDV(1), o SPE ultrapassa o limiar consistentemente nas primeiras amostras pós-falha, demonstrando detecção rápida e confiável. Para IDV(3), o SPE permanece abaixo do limiar durante praticamente toda a janela pós-falha.

Falha	Descrição	FDR	FAR
IDV(1)	Variação degrau razão A/C	> 95%	< 1%
IDV(3)	Variação degrau temp. alim. D	< 5%	< 1%

4.3 Interpretação Geométrica

A projeção das trajetórias no espaço $PC1 \times PC2$ revela a causa geométrica da diferença:

- **IDV(1)**: os pontos pós-falha deslocam-se para fora da nuvem de operação normal nesse plano, gerando alto SPE.
- **IDV(3)**: os pontos pós-falha permanecem misturados à nuvem normal, indicando que a falha se manifesta inteiramente dentro do subespaço $\mathcal{S}_k$, o SPE, que mede apenas a distância a esse subespaço, é estruturalmente insensível a esse tipo de desvio.

4.4 Análise de Sensibilidade, Curva ROC

A variação de $\alpha \in \{0,1; 0,2; \dots; 0,9\}$ mostra que a AUC sobre as 20 falhas é máxima em $\alpha = 0,1$ (0,936) e permanece relativamente estável, entre 0,90 e 0,91, para $\alpha \geq 0,2$, valendo 0,901 em $\alpha = 0,9$. Modelos mais compactos são levemente mais sensíveis ao conjunto heterogêneo de falhas; ainda assim, nenhum valor de α resolve falhas como IDV(3), cujo efeito se manifesta dentro do subespaço e exige uma abordagem não linear.

5 Limitações e Trabalhos Futuros

O SPE captura apenas desvios que projetam a observação para fora do subespaço $\mathcal{S}_k$; falhas confinadas dentro dele, como IDV(3), permanecem, por construção, invisíveis, consequência da natureza **linear** do PCA. Spina et al. [4] comparam *autoencoders* (AE, VAE, DAE) com o PCA no mesmo benchmark TEP: para a Falha 3, o PCA tem o menor AUC entre os métodos (0,718) contra até 0,763 dos autoencoders, evidência de que a extração não linear capta estrutura que o PCA não representa. Isso aponta uma extensão natural: substituir $V_k V_k^T$ por um *autoencoder* não linear, mantendo o treino semi-supervisionado e o SPE como estatística de monitoramento.

6 Conclusão

Demonstramos que o PCA fundamentado na decomposição espectral da matriz de covariância é uma ferramenta eficaz e interpretável para detecção de anomalias em processos industriais. A aplicação ao TEP evidencia tanto a capacidade do método (IDV(1): FDR > 95%) quanto sua limitação estrutural (IDV(3): FDR < 5%), explicada geometricamente pela projeção no espaço de componentes principais. O desenvolvimento de um monitor em tempo real, implementado como aplicação de linha de comando com saída ANSI, ilustra a viabilidade prática da abordagem.

Referências

- [1] S.J. Qin. Statistical process monitoring: basics and beyond. *Journal of Chemometrics*, 17(8–9):480–502, 2003.
- [2] J.J. Downs and E.F. Vogel. A plant-wide industrial process control problem. *Computers & Chemical Engineering*, 17(3):245–255, 1993.
- [3] C.A. Rieth, B.D. Amsel, R. Tran, and M.B. Cook. Additional Tennessee Eastman Process Simulation Data for Anomaly Detection Evaluation. Harvard Dataverse, 2017. DOI: 10.7910/DVN/6C3JR1.
- [4] D.E. Spina et al. Comparison of autoencoder architectures for fault detection